aut : HUST-李俊

Overview

通过一系列的project，来搭建起来一个基于raft 一致性算法的分布式键值存储

- project1： 构建一个独立的 kv server（只有1个node)
- project2： 基于raft算法实现分布式键值服务器

  -2a：实现基本的raft一致性算法，三个部分-a：Leader选举 , -b:日志同步，-c:节点接口

  -2b：利用2a实现的Raft算法模块来构建分布式kv数据库服务端

  -2c：利用snapshot对服务器进行日志压缩（服务器不能让日志无限增长）
- project3： 在project2的基础上支持多个Raft集群

  -3a：对raft算法补充成员变更和leader变更逻辑。

  -3b：使服务端支持3a的功能 ， 并实现区域分割。

  -3c：为调度器实现调度操作，具体是为`Scheduler`实现`AddPeer`和`RemovePeer`命令。
- project4： 构建`transaction system`实现多客户端通信，主要两个部分：`MVCC`和`transactional API`

Project1

总结：

这一部分直接使用badger作为存储引擎，无需自行定义，编程前可以学习一下badger中的API，对badger数据库的get、put、delete等操作在框架代码中已基本提供，实现时只需构造相应的参数并调用对应的函数即可。

两件事：

①实现一个standalone storage engine

由于是lab1，还没有引入分布式，现在只要写一个单进程的storage engine，实现tinykv 中已经定义好的storage interface。

不用自己去写一个存储引擎，tinykv已经实现了一个badger db，只需要调用badger db的相关接口就能实现存储操作。

②实现server的gRPC接口

server需要实现好四个rpc接口（Get,Put,Delete,Scan),只需要调用standalone storage engine提供的方法做一点额外处理就行

代码编写部分：

- `server`：该目录下的`server.go`是需要补充的文件之一，`Server`结构体是与客户端链接的部分，需要实`Put/Delete/Get/Scan`这几个操作。
- `storage`：主要关注`modify.go`、`storage.go`和`standalone_storage/standalone_storage.go`，这也是上述提到的引擎部分，`Server`结构体中的`storage`也就是这里的standalone_storage
- `util`：重点关注`engine_util`下的`engines.go`，`write_batch.go`，`cf_iterator.go`，通过`engine_util`提供的方法执行所有读/写操作

注意点： `server_test.go`这个是测试文件，错误都需要这找原因。

测试结果：

```
GO111MODULE=on go test -v --count=1 --parallel=1 -p=1 ./kv/server -run 1
=== RUN   TestRawGet1
--- PASS: TestRawGet1 (0.89s)
=== RUN   TestRawGetNotFound1
--- PASS: TestRawGetNotFound1 (0.96s)
=== RUN   TestRawPut1
--- PASS: TestRawPut1 (1.00s)
=== RUN   TestRawGetAfterRawPut1
--- PASS: TestRawGetAfterRawPut1 (0.97s)
=== RUN   TestRawGetAfterRawDelete1
--- PASS: TestRawGetAfterRawDelete1 (1.01s)
=== RUN   TestRawDelete1
--- PASS: TestRawDelete1 (1.14s)
=== RUN   TestRawScan1
--- PASS: TestRawScan1 (0.91s)
=== RUN   TestRawScanAfterRawPut1
--- PASS: TestRawScanAfterRawPut1 (0.83s)
=== RUN   TestRawScanAfterRawDelete1
--- PASS: TestRawScanAfterRawDelete1 (0.89s)
=== RUN   TestIterWithRawDelete1
--- PASS: TestIterWithRawDelete1 (0.81s)
PASS
ok      github.com/pingcap-incubator/tinykv/kv/server   9.471s
lygin@ubuntu:~/Desktop/tinykv$
```

Project2

总结：

主要是Raft算法的实现与封装应用，即基于raft算法实现分布式键值服务器

2A.实现Raft算法

2B.基于Raft算法构建分布式kv数据库服务端

2C.在2B的基础上增加日志压缩和安装快照的相关处理逻辑

Raft一致性算法

①Raft将系统中的角色分为领导者（Leader）、跟从者（Follower）和候选人（Candidate）：

- **Leader**：接受客户端请求，并向Follower同步请求日志，当日志同步到大多数节点上后告诉Follower提交日志。
- **Follower**：接受并持久化Leader同步的日志，在Leader告之日志可以提交之后，提交日志。
- **Candidate**：Leader选举过程中的临时角色。

②Raft要求系统在任意时刻最多只有一个Leader，正常工作期间只有Leader和Followers。

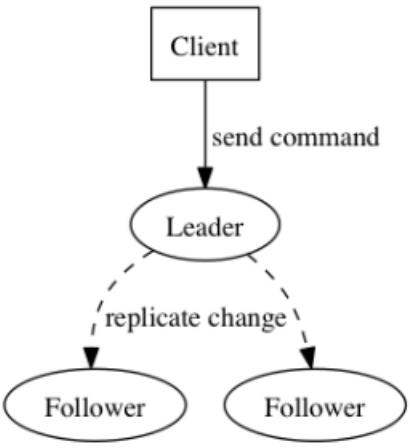

③三者之间的角色状态转换

Follower只响应其他服务器的请求。如果Follower超时没有收到Leader的消息，它会成为一个Candidate并且开始一次Leader选举。收到大多数服务器投票的Candidate会成为新的Leader。Leader在stop之前会一直保持Leader的状态。

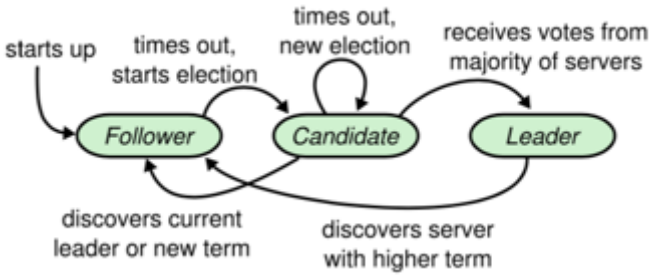

Steps:

- Leader选举：Leader通过定期向所有Followers发送心跳信息维持其统治

  Raft 使用心跳（heartbeat）触发Leader选举。当服务器启动时，初始化为Follower。Leader向所有Followers周期性发送heartbeat。如果Follower在选举超时时间内没有收到Leader的heartbeat，就会等待一段随机的时间后发起一次Leader选举。

  代码编写部分： `raft/raft.go`

  注意点：论文只提到投票数多于一半时变成leader，但没有说反对数多余一半时变成follower，所以这部分得自己加，否则有些测试过不去。

- 日志同步：Leader通过强制Followers复制它的日志来处理日志的不一致，Followers上的不一致的日志会被Leader的日志覆盖。

  Leader选出后，就开始接收客户端的请求。Leader把请求作为日志条目（Log entries）加入到它的日志中，然后并行的向其他服务器发起 `AppendEntries` 复制日志条目。当这条日志被复制到大多数服务器上，Leader将这条日志应用到它的状态机并向客户端返回执行结果。

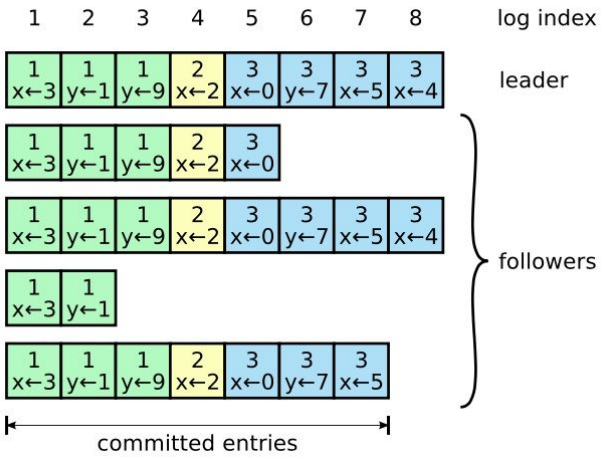

  代码编写部分： `raft/raft.go` `raft/log.go`

  注意点：此时没有实现日志压缩，可以对其进行修改，分阶段缩小测试规模进行测试。

- 实现Rawnode接口：`raft.RawNode`是与上层应用程序交互的接口，如发送`message`给其他`Peer`

  代码编写部分： `raft/rawnode.go`

- 根据自己的理解，理清楚整个流程（个人理解5层）：

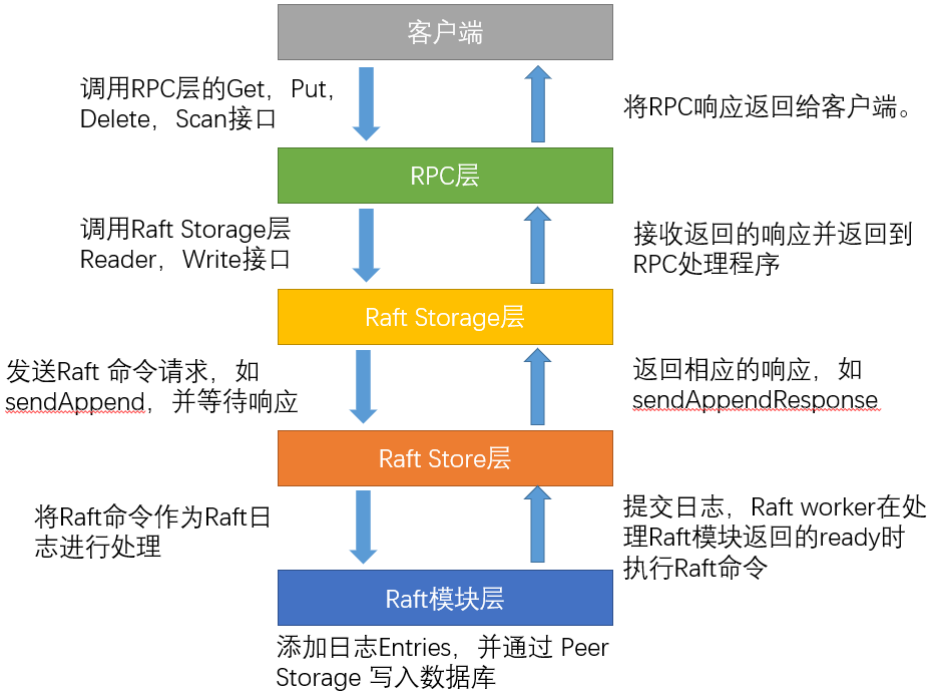

代码编写部分：`kv/raftstore/peer_msg_handler.go`中处理Raft命令的`proposeRaftCommand` func

处理Raft返回ready时的`handleRaftReady`函数

注意点：2b复杂的测试函数，可能会因内存不足导致卡死，可以修改Makefile逐一对测试函数进行测试。

- 日志压缩：实际的系统中，不能让日志无限增长。Raft采用对整个系统进行snapshot来解决，snapshot之前的日志都可以丢弃。

  Snapshot中包含:

  1.日志元数据。最后一条已提交的 log entry的`log index`和`term`。这两个值在snapshot之后的第一条log entry的AppendEntries RPC的完整性检查的时候会被用上。

  2.系统当前状态

  代码编写部分：`raftstore/peer.go` `raft/raft.go` `raft/log.go`

- 成员变更：每次只能增加或删除一个成员。由Leader发起，得到多数派确认后，返回客户端成员变更成功。(Project3)

- 安全性：主要通过控制`term`与`log index`实现（Project3）

  拥有最新的已提交的log entry的Follower才有资格成为Leader。

  Leader只能推进commit index来提交当前term的已经复制到大多数服务器上的日志，旧term日志的提交要等到提交当前term的日志来间接提交（log index 小于 commit index的日志被间接提交）。

  测试结果：

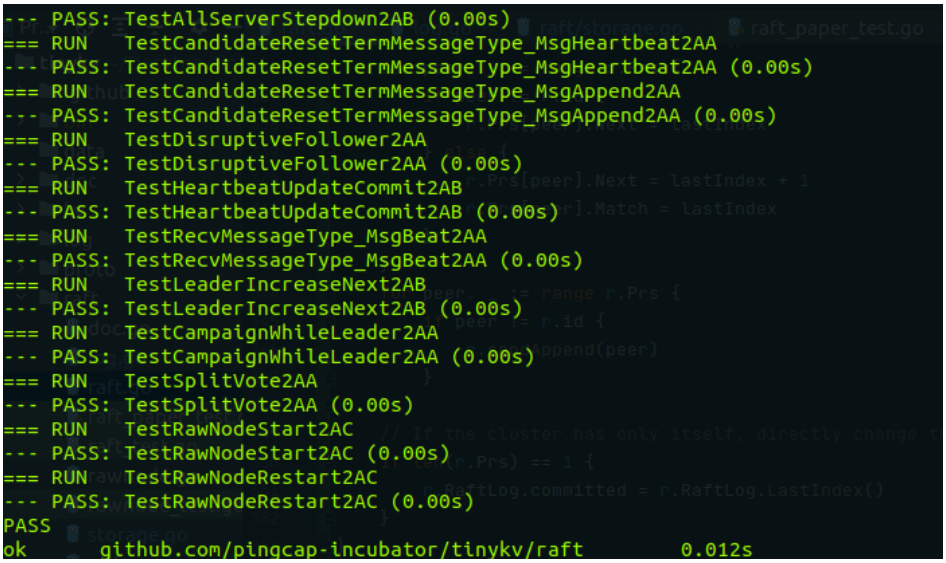

raft论文笔记

复制状态机

1. 复制状态机通过日志实现
- 每台机器一份日志
- 每个日志条目包含一条命令
- 状态机按顺序执行命令

2.应用于实际系统的一致性算法一般有以下特性

- 确保安全性
- 高可用性
- 不依赖时序保证一致性
- 一条命令能够尽可能快的在大多数节点对一轮RPC调用响应时完成

3.Paxos 算法的不足

- 算法复杂度高, 较难理解
- 工程复杂度高, 难以在实际环境中实现

Raft 设计原则

- 概念分解
  - Leader election
  - Log replication
  - Membership changes
- 通过减少状态数量将状态空间简化
  - 日志不允许出现空洞, 并且 raft 限制了日志不一致的可能性
  - 使用随机化时钟简化了领导选举的算法

Raft 一致性算法

State (状态)

在所有服务器上持久存储的(响应RPC之前稳定存储的)

currentTerm	服务器最后知道的任期号(从0开始递增)
votedFor	在当前任期内收到选票的候选人Id(如果没有就为null)
log[]	日志条目, 每个条目包含状态机要执行的命令以及从Leader收到日志时的任期号

在所有服务器上不稳定存在的

commitIndex	已知被提交的最大日志条目索引
lastApplied	已被状态机执行的最大日志条目索引

在Leader服务器上不稳定存在的

nextIndex[]	对于每一个follower, 记录需要发给他的下一条日志条目的索引
matchIndex[]	对于每一个follower, 记录已经复制完成的最大日志条目索引

AppendEntries RPC (日志复制)

由leader通过RPC向follower复制日志, 也会用作heartbeat

入参

term	Leader任期号
leaderId	Leader id, 为了能帮助客户端重定向到Leader服务器
prevLogIndex	前一个日志的索引
prevLogTerm	前一个日志所属的任期
entries[]	将要存储的日志条目列表(为空时代表heartbeat, 有时候为了效率会发送超过一条)
leaderCommit	Leader已提交的日志条目索引

返回值

term	当前的任期号, 用于leader更新自己的任期号
success	如果其他follower包含能够匹配上prevLogIndex和prevLogTerm的日志, 那么为真

接收日志的follower需要实现的

1. 如果term < currentTerm, 不接受日志并返回false
2. 如果索引prevLogIndex处的日志的任期号与prevLogTerm不匹配, 不接受日志并返回false
3. 如果一条已存在的日志与新的冲突(index相同但是term不同), 则删除已经存在的日志条目和他之后所有的日志条目
4. 添加任何在已有日志中不存在的条目
5. 如果leaderCommit > commitIndex, 则设置commitIndex = min(leaderCommit, index of last new entry)

RequestVote RPC (投票请求)

入参

term	**候选人的任期号**
candidateId	发起投票请求的候选人id
lastLogIndex	候选人最新的日志条目索引
lastLogTerm	候选人最新日志条目对应的任期号

返回值

term	**目前的任期号, 用于候选人更新自己**
voteGranted	如果候选人收到选票, 那么为true

接收日志的follower需要实现的

1. 如果term < currentTerm, 那么拒绝投票并返回false
2. 如果votedFor为空或者与candidateId相同, 并且候选人的日志和自己一样新或者更新, 那么就给候选人投票并返回true

服务器要遵守的规则

- 所有服务器:
  - 如果commitIndex > lastApplied, 那么将lastApplied自增并把对应日志log[lastApplied]应用到状态机
  - 如果RPC请求或响应包含一个term T大于currentTerm, 那么将currentTerm赋值为T并立即切换状态为follower
- Follower:
  - 无条件响应来自candidate和leader的RPC
  - 如果在选举超时之前没收到任何来自leader的AppendEntries RPC或RequestVote RPC, 那么自己转换状态为candidate
- Candidate:
  - 转变为candidate之后开始发起选举
    - currentTerm自增 –> 重置选举计时器 –> 给自己投票 –> 向其他服务器发起RequestVote RPC
  - 如果收到了来自大多数服务器的投票, 转换状态成为leader
  - 如果收到了来自新leader的AppendEntries RPC(Heartbeat), 转换状态为follower
  - 如果选举超时, 开始新一轮的选举
- Leader:
  - 一旦成为leader, 想其他所有服务器发送空的AppendEntries RPC(Heartbeat), 并在空闲时间重复发送以防选举超时
  - 如果收到来自客户端的请求, 向本地日志追加条目并向所有服务器发送AppendEntries RPC, 在收到大多数响应后将该条目应用到状态机并回复响应给客户端
  - 如果leader上一次收到的日志索引大于一个follower的nextIndex, 那么通过AppendEntries RPC将nextIndex之后的所有日志发送出去; 如果发送成功, 将follower的nextIndex和matchIndex更新, 如果由于日志不一致导致失败, 那么将nextIndex递减并重新发送

- 如果存在一个N > commitIndex和半数以上的matchIndex[i] >= N并且log[N].term == currentTerm, 将commitIndex赋值为N

一致性算法总结

Election Safety	**选举安全原则: 一个任期内最多允许有一个leader**
Leader Append-Only	只增加日志原则: Leader只会增加日志条目, 永远不会覆盖或删除自己的日志
Log Matching	日志匹配原则: 如果两个日志在相同的的索引位置上并且任期号相同, 那么就可以认为这个日志从头到这个索引位置之间的条目完全相同
Leader Completeness	领导人完整性原则: 如果一个日志条目在一个给定任期内被提交, 那么这个条目一定会出现所有任期号更大的leader中
State Machine Safety	状态机安全原则: 如果一个服务器已经将给定索引位置上的日志条目应用到状态机, 那么所有其他服务器不可能在该索引位置应用不同的日志条目

Raft中的RPC通信

- RequestVote RPC
- AppendEntries RPC
  - 日志条目
  - 心跳
- InstallSnapshot RPC

任期逻辑时钟

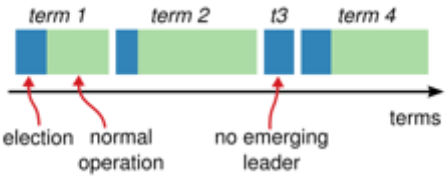

时间被划分为一个个任期(term), 每一个任期的开始都是leader选举, 在成功选举之后, 一个leader会在任期内管理整个集群, 如果选举失败, 该任期就会因为没有leader而结束, 这个转变会在不同的时间的不同的服务器上被观察到

领导人选举流程

- follower –> candidate (选举超时触发)
  - candidate –> leader
    - 赢得了选举
  - candidate –> follower
    - 另一台服务器赢得了选举
  - candidate –> candidate
    - 一段时间内没有任何一台服务器赢得选举

选举活锁(多个节点超时同时选主)

随机的选举超时时间

Raft日志机制的特性

- 如果在不同的日志中的两个条目有着相同的索引和任期号, 那么他们存储的命令肯定是相同的
  - 源于leader在一个任期里给定的一个日志索引最多创建一条日志条目, 同时该条目在日志中的位置也从不会改变
- 如果在不同的日志中的两个条目有着相同的索引和任期号, 那么他们之前的所有日志条目都是完全一样的
  - 源于AppendEntries RPC的一个简单的一致性检查: 当发送一个AppendEntries RPC时leader会把新日志之前的一个日志条目的索引位置和任期号都包含在里面, follower会检查是否与自己的日志中的索引和任期号是否匹配, 如果不匹配就会拒绝这个日志条目, 接下来就是归纳法来证明了
- leader通过强制follower复制它的日志来处理日志的不一致
  - 为了是follower的日志同自己的一致, leader需要找到follower与它日志一致的索引位置并让follower删除该位置之后的条目, 然后再讲自己再该索引位置之后的条目发送给follower, 这些操作都在AppendEntries RPC进行一致性检查时完成
  - leader为每一个follower维护了一个nextIndex, 用来表示将要发送给该follower的下一条日志条目索引, 当一个leader开始掌权时, 会将nextIndex初始化为它的最新日志条目索引值+1, 如果follower在一致性检查过程中发现自己的日志和leader不一致, 会在这个AppendEntries RPC请求中返回失败, leader收到响应之后会将nextIndex递减然后重试, 最终nextIndex会达到一个leader和follower日志一致的位置, 这个时候AppendEntries RPC会成功, follower中冲突的日志条目也被移除了, 此时follower和leader的日志就一致了

安全性

- 选举限制
  - 用投票规则的限制来组织日志不全的服务器赢得选举
    - RequestVote RPC限制规则: 拒绝日志没自己新的candidate
  - Leader永远不会覆盖自己的日志条目
  - 日志条目只能从leader流向follower
- 如何提交上一个任期的日志条目
  - 全程保持自己的任期号
- 安全性论证
  - 领导人完整性原则(Leader Completeness)
    - 如果一个日志条目在一个给定任期内被提交, 那么这个条目一定会出现所有任期号更大的leader中
  - 状态机安全原则(State Machine Safety)
    - 如果一个服务器已经将给定索引位置上的日志条目应用到状态机, 那么所有其他服务器不可能在该索引位置应用不同的日志条目

Follower和Candidate崩溃

- 无限重试
- AppendEntries RPC是幂等的

时序和可用性

broadcastTime << electionTimeout << MTBF

broadcastTime	一台服务器并行的向集群中其他节点发送RPC并且收到它们响应的平均时间
electionTimeout	选举的超时时间
MTBF	是指单个服务器发生故障的时间间隔的平均数

- broadcastTime应该比electionTime小一个数量级, 目的是让leader能够持续发送心跳来阻止follower们开始选举; 根据已有的随机化超时前提, 这个不等式也将瓜分选票的可能性降低到很小
- electionTimeout也要比MTBF小一个几个数量级, 目的是能使系统稳定运行, 当leader崩溃时, 整个集群大约会在electionTimeout的时间内不可用

集群成员变化

下图节点集群扩展到5节点集群, 直接扩展可能导致Server1和Server2构成老集群多数派, Server3, Server4和Server5构成新集群多数派, 两者不相交从而导致决议冲突

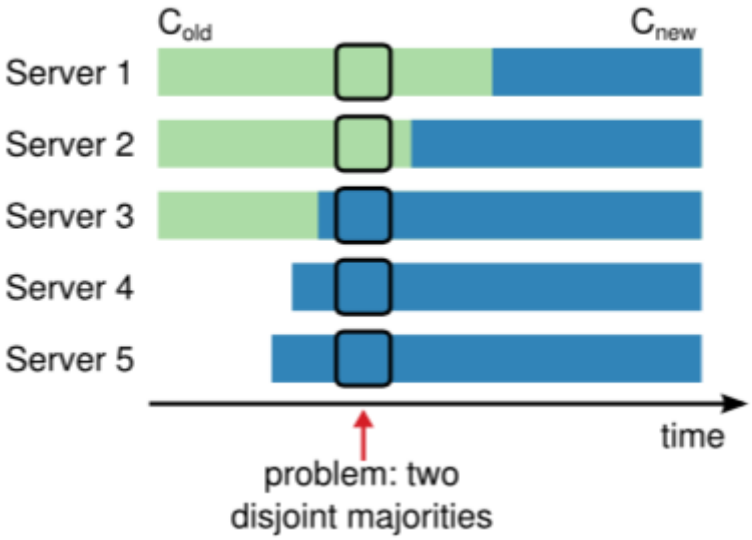

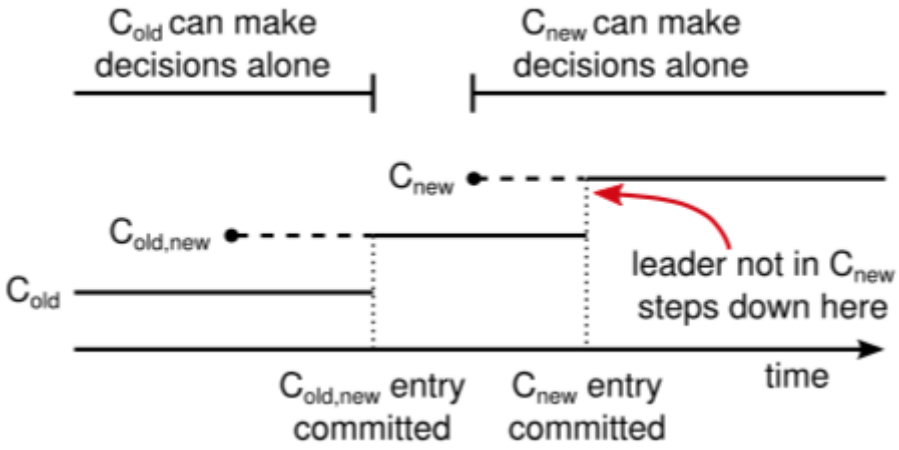

Raft采用联合一致性的方式来解决节点变更, 先提交一个包含新老节点结合的Configuration, 当这条消息commit之后再提交一个只包含新节点的Configuration, 具体流程如下:

1. 首先对新节点进行CaughtUp追数据
2. 全部新节点完成CaughtUp之后, 向新老集合发送Cold+new命令
3. 如果新节点集合多数和老节点集合多数都应答了Cold+new, 就向新老节点集合发送Cnew命令

4. 如果新节点集合多数应答了Cnew, 完成节点切换

日志压缩

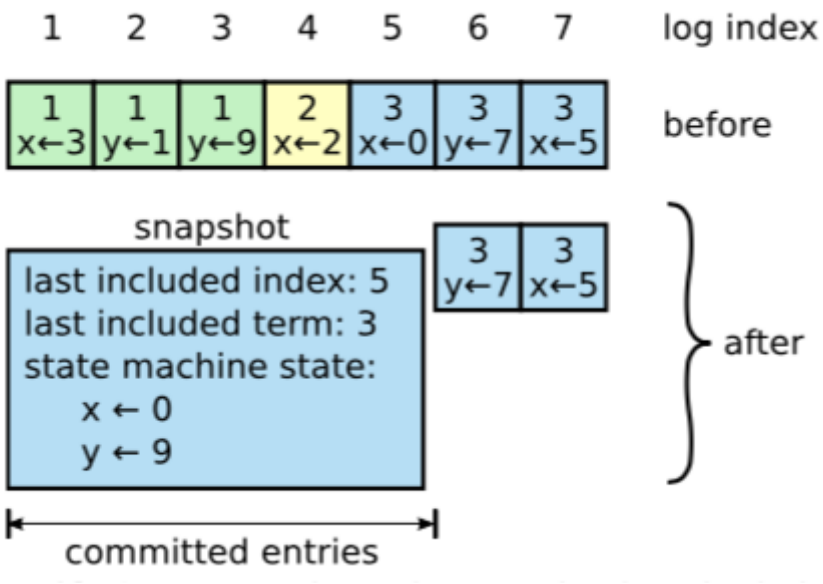

- 每个服务器独立的创建快照, 只包含已被提交的日志
- 快照内容主要包括
  - 状态机的状态
  - Raft的少量元数据(见上图), 保留这些元数据是为了快照后对紧接着的一个AppendEntries进行一致性检查
  - 为了支持集群成员变化, 最新的配置(Configuration)也会作为一个条目被保存在快照中

快照分块传输(InstallSnapshot RPC)

- 虽然多数情况都是每个服务器独立创建快照, 但是leader有时候必须发送快照给一些落后太多的follower, 这通常发生在leader已经丢弃了下一条要发给该follower的日志条目(Log Compaction时清除掉了)的情况下

term	**leader任期**
leaderId	Leader id, 为了能帮助客户端重定向到Leader服务器
lastIncludedIndex	快照中包含的最后日志条目的索引值
lastIncludedTerm	快照中包含的最后日志条目的任期号
offset	分块在快照中的偏移量
data[]	快照块的原始数据
done	如果是最后一块数据则为真

接收者需要实现的

- 如果term < currentTerm立刻回复
- 如果是第一个分块 (offset为0) 则创建新的快照
- 在指定的偏移量写入数据
- 如果done为false, 则回复并继续等待之后的数据
- 保存快照文件, 丢弃所有已存在的或者部分有着更小索引号的快照
- 如果现存的日志拥有相同的最后任期号和索引值, 则后面的数据继续保留并且回复
- 丢弃全部日志

- 能够使用快照来恢复状态机 (并且装载快照中的集群配置)

客户端交互

- 客户端只将请求发送给领导人原则
- 线性一致读
  - 写raft log走状态机
  - Leader与过半机器交换心跳信息确定自己仍然是leader后可提供线性一致读
  - 利用心跳机制提供租约机制(Lease read), 但是依赖本地时钟的准确性

参考资料：

①stanford教授讲解的视频：https://www.youtube.com/results?search_query=raft+algorithm&pbjreload=102

②Wiki：https://en.wikipedia.org/wiki/Raft_(algorithm)

③Paper：也是stranford的大牛写的 https://web.stanford.edu/~ouster/cgi-bin/papers/raft-atc14

Project3

总结：

在project2的基础上支持多个Raft集群。

3A. 在raft模块增加处理增删节点、转换leader的相关处理逻辑

3B. 在服务端增加处理增删节点、转换leader、region split的相关逻辑

3C. 通过regionHeartbeat更新scheduler中的相关信息、实现Schedule函数生成调度操作，避免store中有过多region

3A.在Raft模块增加领导者更改和成员更改

在Raft模块增加MsgTransferLeader，EntryConfChange，MsgHup相关处理逻辑

3B.在RaftStore中增加领导者更改、成员更改、区域分割

（1）领导者更改

proposeRaftCommand中直接调用rawnode的TransferLeader并返回相应的response即可

（2）成员更改

proposeRaftCommand中调用rawnode的ProposeConfChange

handleraftready中更新confver、ctx.storeMeta、PeerCache等相关信息，调用rawnode的ApplyConfChange

（3）区域分割

Region中维护了该region的start key和end key，当Region中的数据过多时应对该Region进行分割，划分为两个Region从而提高并发度，执行区域分割的大致流程如下：

1. split checker检测是否需要进行Region split，若需要则生成split key并发送相应命令
2. proposeRaftCommand执行propose操作
3. 提交后在HandleRaftReady对该命令进行处理：

- 检测split key是否在start key 和end key之间，不满足返回
- 创建新region 原region和新region key范围为start$_{split}$，$_{split}$end
- 更新d.ctx.storeMeta中的regionranges和regions
- 为新region创建peer，调insertPeerCache插入peer信息
- 发送MsgTypeStart消息

4. 执行get命令时检测请求的key是否在该region中，若不在该region中返回相应错误

3C.实现调度器Schedule

- kv数据库中所有数据被分为几个Region，每个Region包含多个副本，调度程序负责调度每个副本的位置以及Store中Region的个数以避免Store中有过多Region。
- 为实现调度功能，region应向调度程序定期发送心跳，使调度程序能更新相关的信息从而能实现正确的调度，processRegionHeartbea函数实现处理region发送的心跳，该函数通过regioninfo更新raftcluster中的相关信息。
- 为避免一个store中有过多Region而影响性能，要对Store中的Region进行调度，通过Schedule函数实现

project4

总结：

在project3的基础上支持分布式事务

- 4A 实现结构体MvccTxn的相关函数
- 4B 实现server.go中的KvGet, KvPrewrite, KvCommit函数
- 4C 实现server.go中的KvScan, KvCheckTxnStatus, KvBatchRollback,KvResolveLock函数